

Projet Algorithmie 3

La distance de Jaccard

De-backer Cuvelier Sébastien Llobregat Nicolas

Version du 09 Avril 2025

Table des matières

1	Organisation du travail	3
1.1	Outils utilisés	3
1.2	Répartition du travail	3
2	Structure du projet	3
2.1	Les modules	3
2.2	Gestion des options	4
2.3	Gestions des fichiers	4
2.4	Gestion de l'entrée standart	5
3	Choix d'implémentation	6
3.1	Stockage des mots avec holdall	6
3.1.1	Implémentation par LDSC	6
3.1.2	Implémentation par tableaux dynamiques	6
4	Calcul de la distance de Jaccard	6
5	Les difficultés rencontrées	7
5.1	Tentative d'utilisation de getopt	7
5.2	La fonction fscanf	7
6	Performances	8
6.1	Complexité en espace	8
6.2	Complexité en temps	8
7	Améliorations possibles	8

1 Organisation du travail

1.1 Outils utilisés

Git & Github: Pour la gestion du projet et des différentes versions de celui-ci nous avons fait le choix d'utiliser un logiciel de versionning: **GIT**. Ainsi nous avons pu travailler en simultané sur les différentes composantes du projet. La methodology était la suivante: Créations des tâches via les issues **Github**. Puis création d'une branche spécifique pour chaque tâche à réaliser. Une fois le travail réaliser nous ouvrons une **pull request** pour que notre binôme puisse analyser le travail de l'autre avant de mutualiser sur la branche principale.

Tests unitaires: Nous avons pour ambition d'utiliser les tests unitaires pour s'assurer que chaque fonction réalisait bien ce qu'elle devait, pour se faire nous avons commencer à utiliser une bibliothèque qui permettait assez simplement de les réalilser: **greatest**. Cependant il s'est avéré très chronophage et nous avons pris du retard sur ces tests ce qui leur a fait perdre toute utilité. Nous avons donc choisi de ne pas les inclure dans notre version finale du projet.

1.2 Répartition du travail

Mesure de la charge de travail: Au début du projet nous n'avions pas réellement conscience de la charge de travail à effectuer. Il aurait peut-être été intéressant de lors de la première séance de réaliser un planning avec un tableau de répartition des tâches pour définir une charge de travail équitable. Cependant le projet n'étant pas de grande envergure et étant en effectif réduis à deux personnes nous avons pu communiquer efficacement pour communiquer sur les tâches que nous étions entrain de réaliser.

2 Structure du projet

Origine: Lors de la conception de notre binôme nous avons décider de faire une lecture commune du sujet afin de savoir si nous avions la même vision. Ainsi nous avons organiser la structure du projet à l'origine puis nous nous sommes mis d'accord sur les modules à utiliser. Entre les deux implémentations suggérées soit l'utilisation de **tables de hachages** ou bien **d'abres binaires de recherches équilibrés**, c'est la deuxième qui nous a paru la plus adéquates. En effet il est plus facile de représenter les arbres et nous avons beaucoup plus travailler sur cette notion en cours.

2.1 Les modules

Les modules utilisés sont:

- Le module **avl**
- Le module **holdall**
- Le module **jdis**
- Le module **op**

Le module holdall: Nous avons eu recours au module **holdall** pour le stockage des mots, afin de séparer le traitement des mots de la gestion en mémoire. Nous aurions pu choisir d'utiliser la fonction **bst_dft_infix_apply_context** du module **avl** et par exemple libérer les ressources en même temps que le dernier parcours de chaque arbre. Nous avons égelment décider de tester cette solution en parallèle et nous en faisons référence dans la section 6 liée aux performances de l'implémentation proposée.

Le module jdis: Nous avons décider de créer un module spécifique pour gérer la liaison entre le module **avl** et notre utilisation, il consiste principalement à convertir un fichier ou l'entrée standart (voir 2.4) en un **avl**. En le calcul du cardinal de l'intersection des ensembles de mots stockés dans les arbres. Et bien évidemment au calcul de la distance de Jaccard entre chaque couple deux à deux distincts des ensembles représentés par les arbres sur laquelle nous reviendrons dans la sous section 4.


Le module op: Il permet principalement d'intervenir lors de l'affichage sur la sortie standart et permet ainsi de désengorger le main et le rendre plus clair. Il comprend donc la fonction qui affiche l'aide ainsi que le graph d'appartenance des mots.

2.2 Gestion des options

2.3 Gestions des fichiers

Pour gerer les fichiers pris en arguments par le programme nous ouvrons simplement le fichier associé en mode lecture seule puis nous lisons (précisions 5.2) chaque mot et nous tentons de l'ajouter à l'arbre binaire associé. À la fin de la lecture nous avons un arbre contenant des pointeurs vers les mots. Il est à noté que pour un même fichier, on stocke en un et un seul exemplaire les mots appraissant plusieurs fois dans le même fichier. Nous avons un tableau avec l'ensemble des arbres créer.

Exemple: Ainsi si nous executons la commande suivante: `./jdis x0.txt x1.txt x2.txt` où les fichiers x0.txt et x1.txt sont ceux donnés dans le sujet du projet, nous aurons la representation suivante:



Exemple 1: Conversion d'un fichier en arbre

2.4 Gestion de l'entrée standard

Questionnement: Nous avons réfléchi comment traiter l'argument particulier '-', deux Choix s'offraient alors à nous, créer l'arbre depuis l'entrée standard directement et donc différencier très clairement les fichiers de l'entrée standard ou bien de stocker l'entrée standard dans un fichier puis effectuer le même traitement que sur les autres arguments sans distinction aucune. Dans un soucis d'homogénéité c'est cette deuxième implémentation qui a été sélectionnée.

Utilisation d'un fichier temporaire: La situation se prête parfaitement à un fichier temporaire, comme vu en cours d'Algorithmie 1, page 39 du support de cours et d'exercices de 2023:

La fonction `tmpfile`:

Crée un fichier temporaire ouvert en mode `w+b`. Ce fichier sera automatiquement supprimé lors de sa fermeture ou d'une terminaison normale du programme; En cas de succès, renvoie un pointeur vers le contrôleur du flot ; En cas d'échec, renvoie `NULL`.

d'où la création de la fonction statique **`stdin...to_file`** dans le module `jdis`. À la suite de ce traitement l'entrée standard est gérée exactement comme les fichiers normaux.

3 Choix d'implémentation

3.1 Stockage des mots avec holdall

3.1.1 Implémentation par LDSC

3.1.2 Implémentation par tableaux dynamiques

4 Calcul de la distance de Jaccard

Les paires distinctes: Nous avons maintenant notre tableau avec des pointeurs vers nos arbres, on peut rappeler que la taille d'un arbre s'effectue en temps constant dans le contrôleur. Nous allons avoir à calculer la distance de Jaccard entre chaque couple deux à deux distincts d'arbres. Pour cela il suffit d'avoir deux boucles imbriquées:

```
1 for (int i = 0; i < k - 1; ++i) {  
2     for (int j = i + 1; j < k; ++j) {  
3         . . .  
4     }  
5 }
```

La première boucle: nous commençons à $i = 0$ et allons jusqu'à $i = k - 2$ (car $i < k - 1$)

La deuxième boucle: pour chaque valeur de i nous commençons à $j = i + 1$ et va jusqu'à $j = k - 1$ (car $j < k$). L'idée ici est de parcourir chaque combinaison unique de i et j où i est strictement inférieur à j . Cela permet de créer une paire unique sans répéter les mêmes éléments dans les deux positions.

Rappel sur la distance de Jaccard: Nous devons maintenant effectuer le calcul de la distance de jaccard, petit rappel sur la formule: La **distance de Jaccard** entre deux ensembles A et B est définie par la formule suivante:

$$J_{\delta}(A, B) = \begin{cases} 0 & \text{si } A = \emptyset \wedge B = \emptyset, \\ 1 - \frac{|A \cap B|}{|A \cup B|} & \text{sinon.} \end{cases}$$

Calcul du cardinal de l'union Nous avons donc besoin du cardinal de l'intersection ainsi que le cardinal de l'union de chaque couple, pour cela nous allons en réalité ne calculer que le cardinal de l'intersection. En effet nous allons utiliser une petite astuce de la théorie des ensembles qui nous dit que: Le cardinal de l'union de deux ensembles n'est rien d'autre que la somme de leurs cardinaux respectifs moins le cardinal de l'intersection. On peut facilement s'en rendre compte ici:




Schéma 1: Généralités sur les ensembles

Calcul du cardinal de l'intersection Nous devons alors calculer l'intersection des deux ensembles, pour cela nous allons de nouveau utiliser la fonction `bst.dft.infix.apply_context` du module `avl`. Cette fois-ci nous allons un contexte qui sera une structure contenant un compteur ainsi que le plus petit des deux ensembles. Ainsi nous allons parcourir le plus grand des deux et rechercher dans le plus petit la référence grâce à la fonction `bst.search` du module `avl`. Si on la trouve alors on ajoute un au compteur cela veut dire qu'elle se trouve dans les deux sinon non. A la fin dans le contexte nous aurons le cardinal de l'ensemble.

Calcul final: Il nous reste plus qu'à rassembler les éléments, ainsi nous avons: Un moins le cardinal de l'intersection divisé par la taille des deux arbres moins le cardinal de l'intersection ce qui nous donne la distance de Jaccard entre les deux ensembles de mots de la paire de fichiers. On peut alors réitérer sur toutes les paires.

5 Les difficultés rencontrées

5.1 Tentative d'utilisation de getopt

La bibliothèque getopt: En premier lieu nous nous sommes intéressés à la bibliothèque `getopt` qui nous permettait de parser la ligne de commande pour trouver les options notamment grâce à `optind` et `optarg`. Nous pouvions également préciser quelles options nécessitaient des paramètres comme pour l'option qui permet de fixer la taille maximale des mots `-iVALUE` ou `-initial=VALUE`. Grâce à `getopt` nous avons pu implanter les options très rapidement, mais nous avons rencontré un problème lorsque nous voulions implanter l'option `'-'` permettant d'échapper le nom d'un fichier. En effet, lorsque nous utilisons cette option nous avons remarqué qu'elle échappait tous les paramètres qui suivaient. Nous avons d'abord cherché une solution en remplaçant `getopt` par `getopt.long`. Ce qui nous compliquait la tâche. Finalement il a été choisi de parser nous même la ligne de commande pour avoir un contrôle total sur son traitement.

5.2 La fonction fscanf

utilisation de fscanf: Afin de créer les arbres comme nous l'avons décrit dans la section 2.3 nous avons besoin de lire dans les fichiers, pour se faire il convient d'usage d'utiliser la fonction `fscanf`, et c'est le choix que nous avons fait

lors de la première partie du projet cependant, après avoir essayer d'implémenter l'option -p (resp. -punctuation-like-space) nous avons un problème de compréhension de la fonction. Il fallait de plus reparser le buffer que nous prenions afin de l'analyser par la suite. En outre cela revenait à lire chacun des caractères deux fois et donc de doubler la complexité temporelle. Il a été alors naturellement convenu de coder notre propre fonction de lecture d'où l'apparition de la fonction statique **hm_fscanf** (hm pour home maid). Ainsi nous lisons caractère par caractère dans le fichier donné par la tête de lecture en paramètre grâce à la fonction **fgetc**. Elle permet de gérer en une seule fois le cas où nous devons prendre en compte la punctuation ou non.

6 Performances

Analyse de quelques données: Nous allons analyser quelques données afin d'avoir une idée de la performance de notre executable, nous verrons ensuite une étude théorique afin de conformer nos observations, enfin nous donnerons quelques pistes d'améliorations.

6.1 Complexité en espace

6.2 Complexité en temps

7 Améliorations possibles